竹芝スマートビル 人流理解の共同研究
進捗のご報告

2026/11/01　東京科学大学

本日のまとめ

- 映像 → 追跡 → VLM → 評価の手順が、仮想空間で一通り動いた
- VLM（映像を見て文章で答える AI）の使い道が絞れてきた
  - 位置で状態が分かる場面は、位置のルールのほうが良い（状態の F1 0.59 対 0.53）
  - 位置で分からない場面は、VLM の向きを足すほうが良い（0.49 対 0.42）
  - どれも仮想の場面の値で、竹芝での性能の見込みではない
- 止まった時刻は VLM では取れない。時刻は追跡から取る形に変える
- 全部の候補に VLM を使うと、カメラ 1 台に GPU 2.0〜2.6 枚分かかる。映像を選んで使う前提
- **竹芝の映像に進むには 5 点のご確認が必要。録画の保全がいちばん急ぐ**

予定と今の位置

時期	計画（10/4 版）	今の状況
10 月末	条件確定（状態の定義・評価仕様）	案はできた。確定には 5 点のご確認が必要で、まだ完了していない
11 月	基準評価（竹芝の映像で基準の数値を取る）	手順と評価の道具は仮想空間で確認済み。映像を受け取れれば始められる
12 月	比較検証（方式を同じ条件で比べる）	比べる方式の準備を進めている。VLM に入れる映像の選び方もここで比べる

- **この間にできたもの**
  - 状態ラベルの定義・評価仕様・データのお願いの案（別の資料）
  - 評価の道具（ラベルを読んで指標を全部出す）と、仮想空間でのリハーサル（オフィス 1 場面・広間 2 場面）

概要の映像（1 分 54 秒・音声なし）



仮想空間の映像（竹芝の映像ではありません）。空間の素材: NVIDIA Isaac Sim（Hospital、CC BY 4.0）。映像はクリックで再生

比べた 3 つの方式

方式	見ているもの	止まっている人の判定
位置のルール	追跡の足元の位置と、止まった時間	EV 待ちエリア → EV 待ち、案内板の前 → 案内確認、それ以外 → 同行者待ち
VLM に状態を聞く	6 秒の映像と軌跡	VLM が状態を直接答える
ルール＋VLM の向き	位置のルールで止まっている人だけ、VLM に向きを聞く	扉 → EV 待ち、案内板 → 案内確認、それ以外 → 同行者待ち

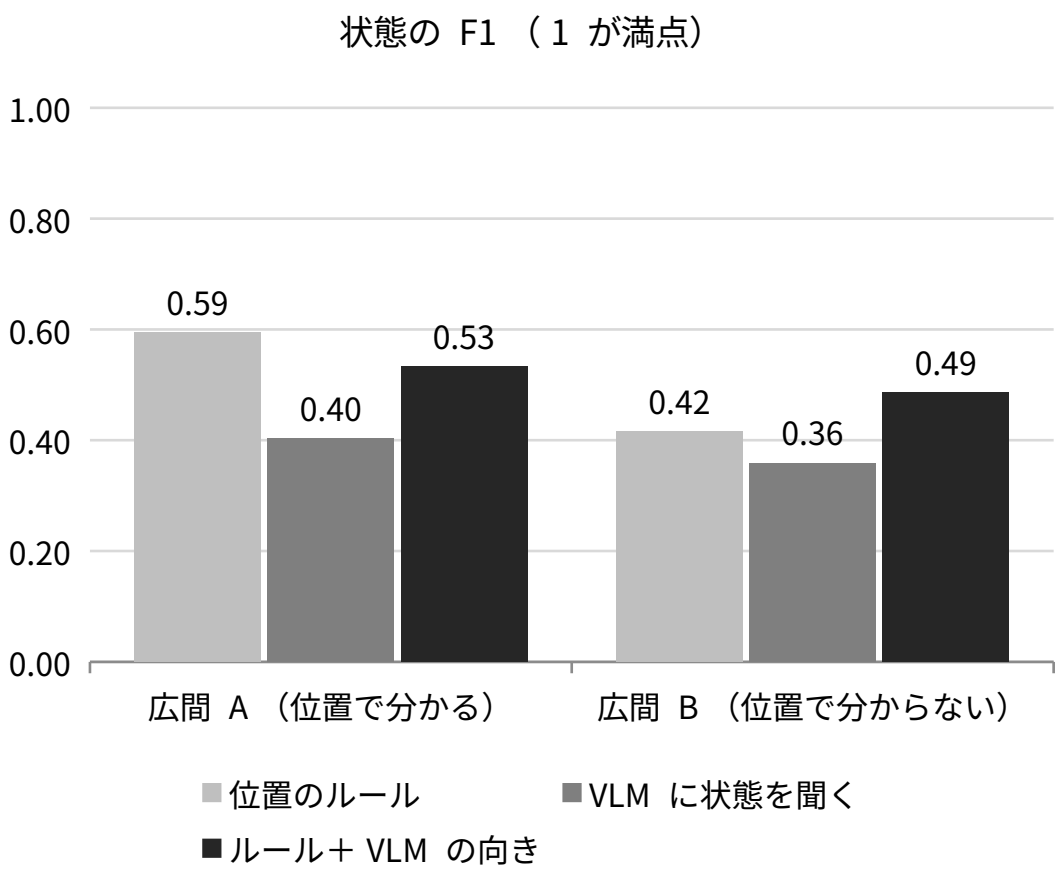
- 歩いている人の判定はどの方式も同じ考え方（通過など）
- **VLM は「同行者を待っている」と見抜いているわけではない。「扉も案内板も向いていない」という観察を、決めた対応で同行者待ちにしている**
- 向きの対応は広間 A の結果を見て決めたもの。広間 B には変えずに当てた

実験の条件（どれも仮想の場面）

項目	広間 A（位置で分かる）	広間 B（位置で分からない）
人数・長さ	94 人・6 分	92 人・6 分
同行者の待つ場所	EV 待ちエリアの外	EV 待ちエリアの中
案内板	待ち列の端から少し離れている	待ち列のすぐ隣
VLM に見せたクリップ	692 本	481 本
評価の数	人 × 0.5 秒で 4,284 段	人 × 0.5 秒で 3,313 段

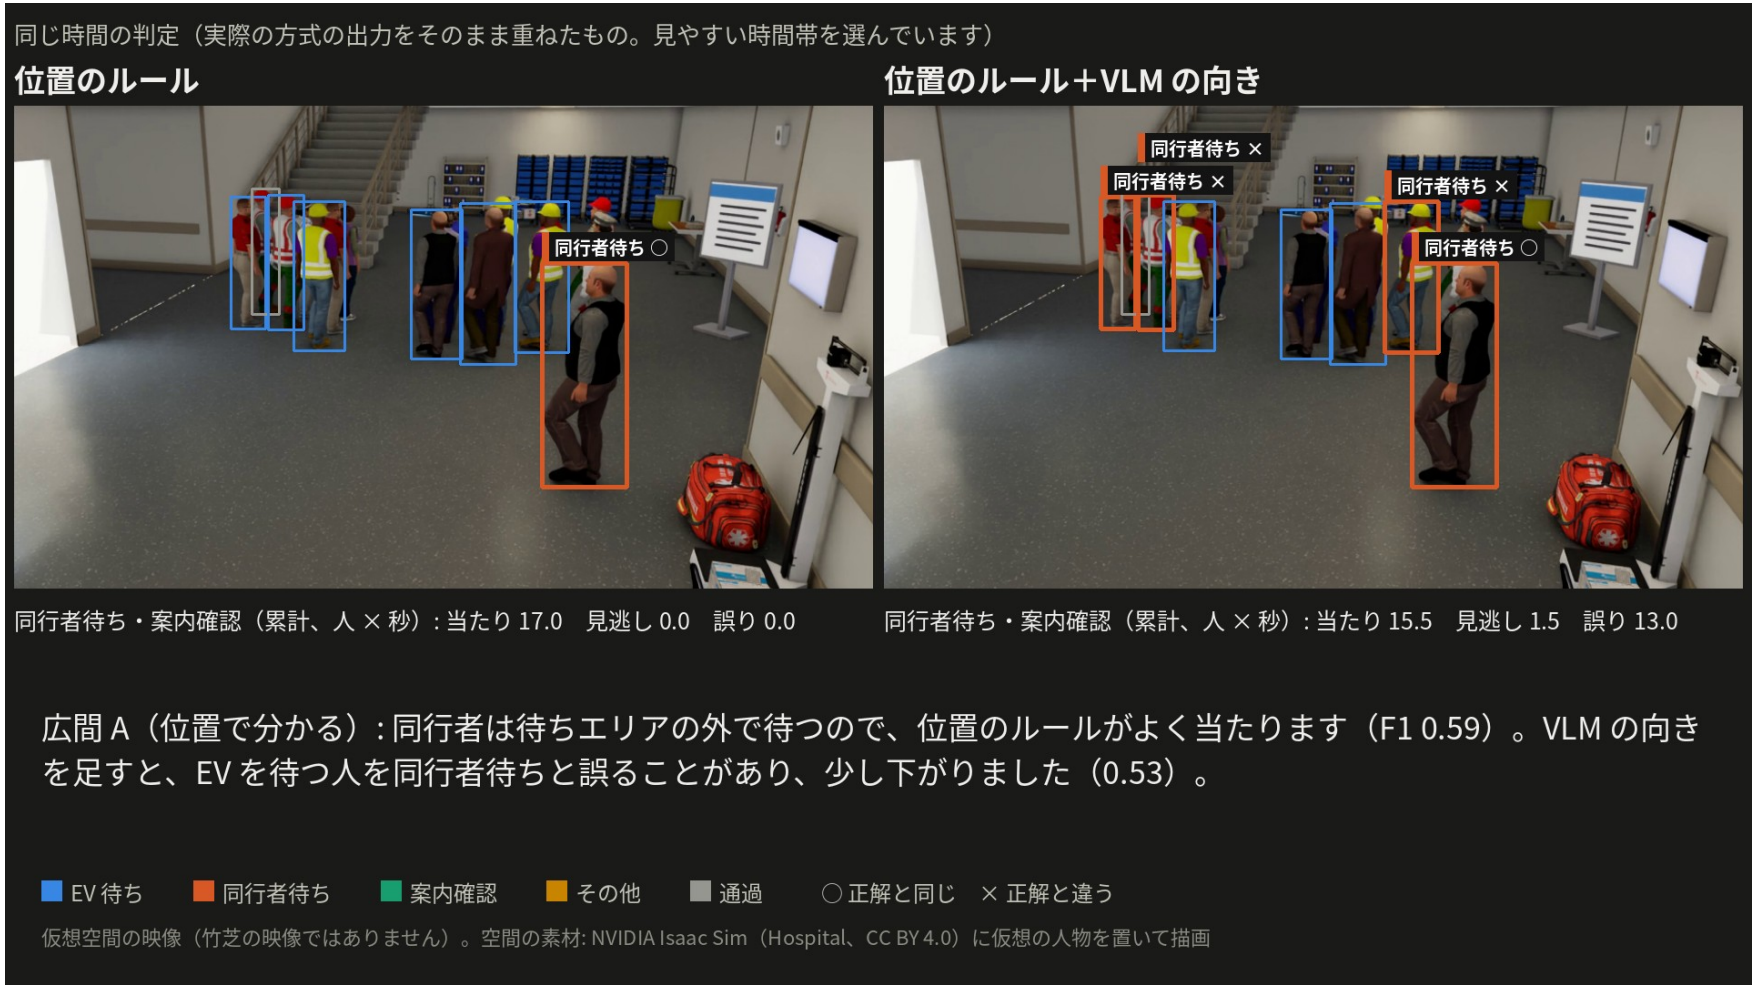
- 追跡: MOPF（YOLO11m＋QAQS＋BoostTrack）。VLM: Qwen3-VL-8B（6 秒のクリップを 3 秒おき、答えの有効期限 8 秒）
- 状態は 5 つ（EV 待ち・同行者待ち・案内確認・通過・その他）。F1 は見逃しと誤りの両方を見る指標で 1 が満点、不明は誤りに数える

結果: VLM の向きが上回るのは、位置で分からない場面だけ



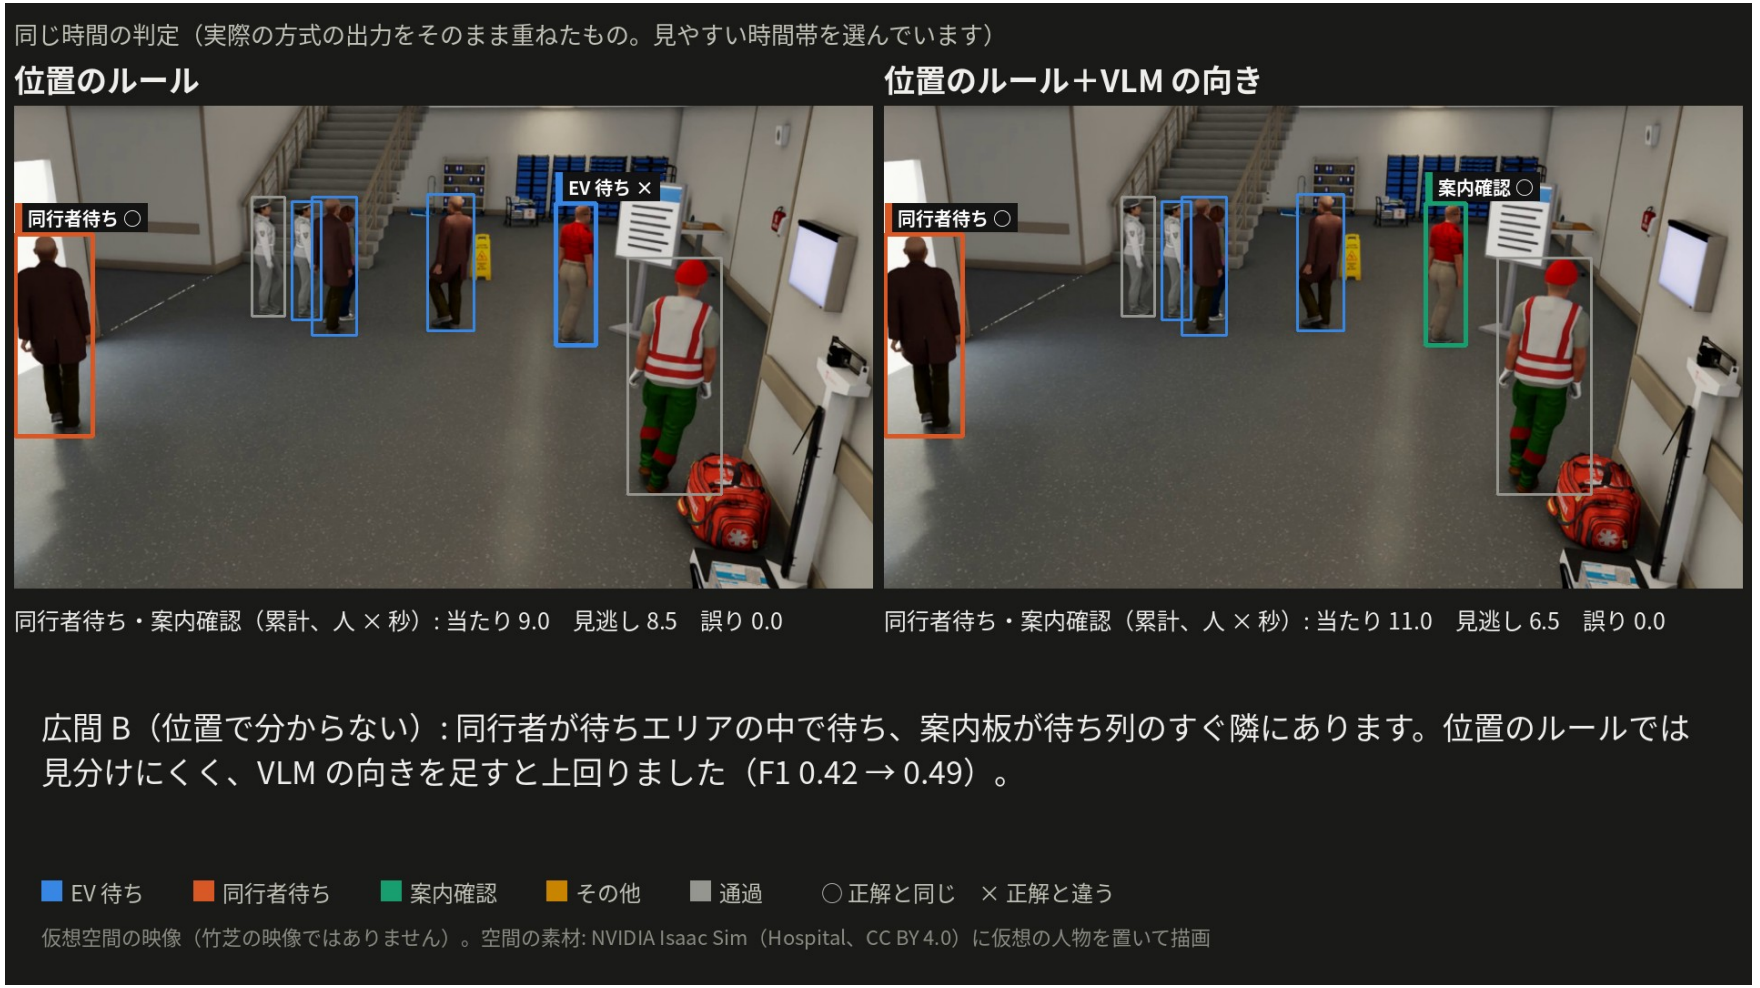
- 広間 A: 位置のルール 0.59（0.57〜0.61）、向き 0.53（0.51〜0.55）
  - 向きを足すと、EV を待つ人を同行者待ちと誤る
- 広間 B: 位置のルール 0.42（0.39〜0.44）、向き 0.49（0.42〜0.53）
  - 95% 区間はわずかに重なる
  - 差の多くは案内確認（F1 0.00 → 0.29）。同行者待ちはほぼ同じ（0.59 → 0.62）
- 状態を直接聞くと、同行者待ちは 1 度も出ない（F1 0）
- **見通し: 位置で分かる所はルール、分からない所に VLM**

映像: 広間 A では、位置のルールがよく当たる



同じ 20 秒を、位置のルール（左）とルール＋VLM の向き（右）で比べたもの。仮想空間の映像（竹芝の映像ではありません）。空間の素材: NVIDIA Isaac Sim（Hospital、CC BY 4.0）

映像: 広間 B では、向きを足すと見分けられる人がいる



同じ 20 秒を、位置のルール（左）とルール＋VLM の向き（右）で比べたもの。仮想空間の映像（竹芝の映像ではありません）。空間の素材: NVIDIA Isaac Sim（Hospital、CC BY 4.0）

例: 位置で分からない人を、向きで見分けられた（広間 B）

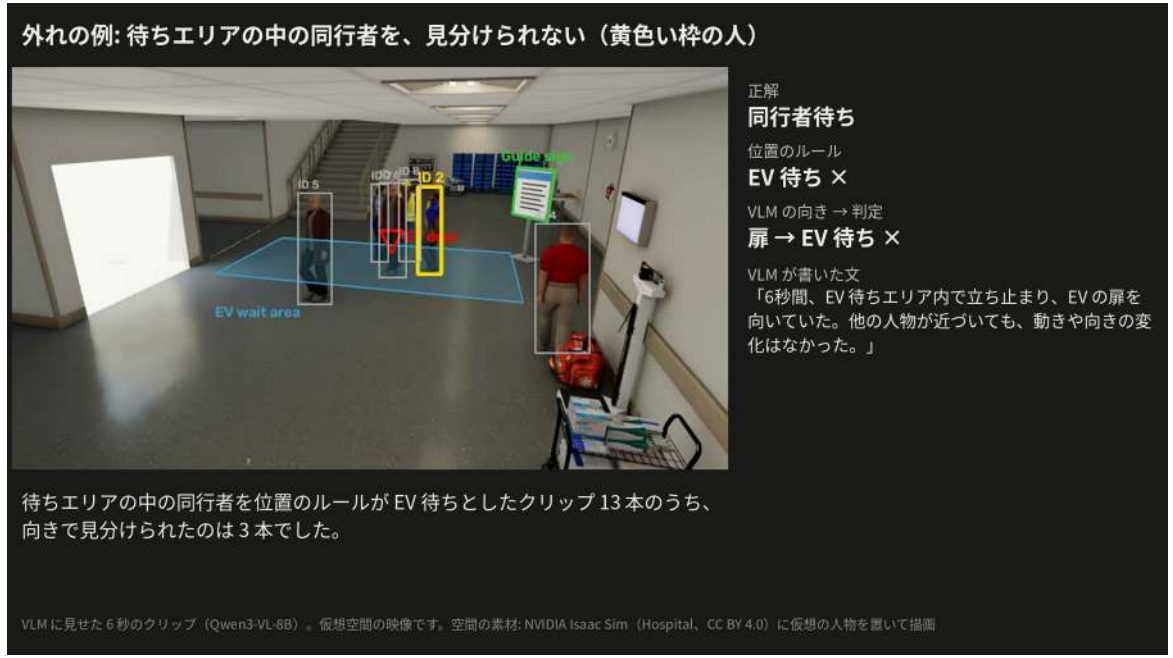




- VLM に見せた 6 秒のクリップそのものと、VLM が書いた文。黄色い枠が聞いた人
- ただし広間 B の案内確認の F1 は 0.29 で、まだ低い

例: 外れ





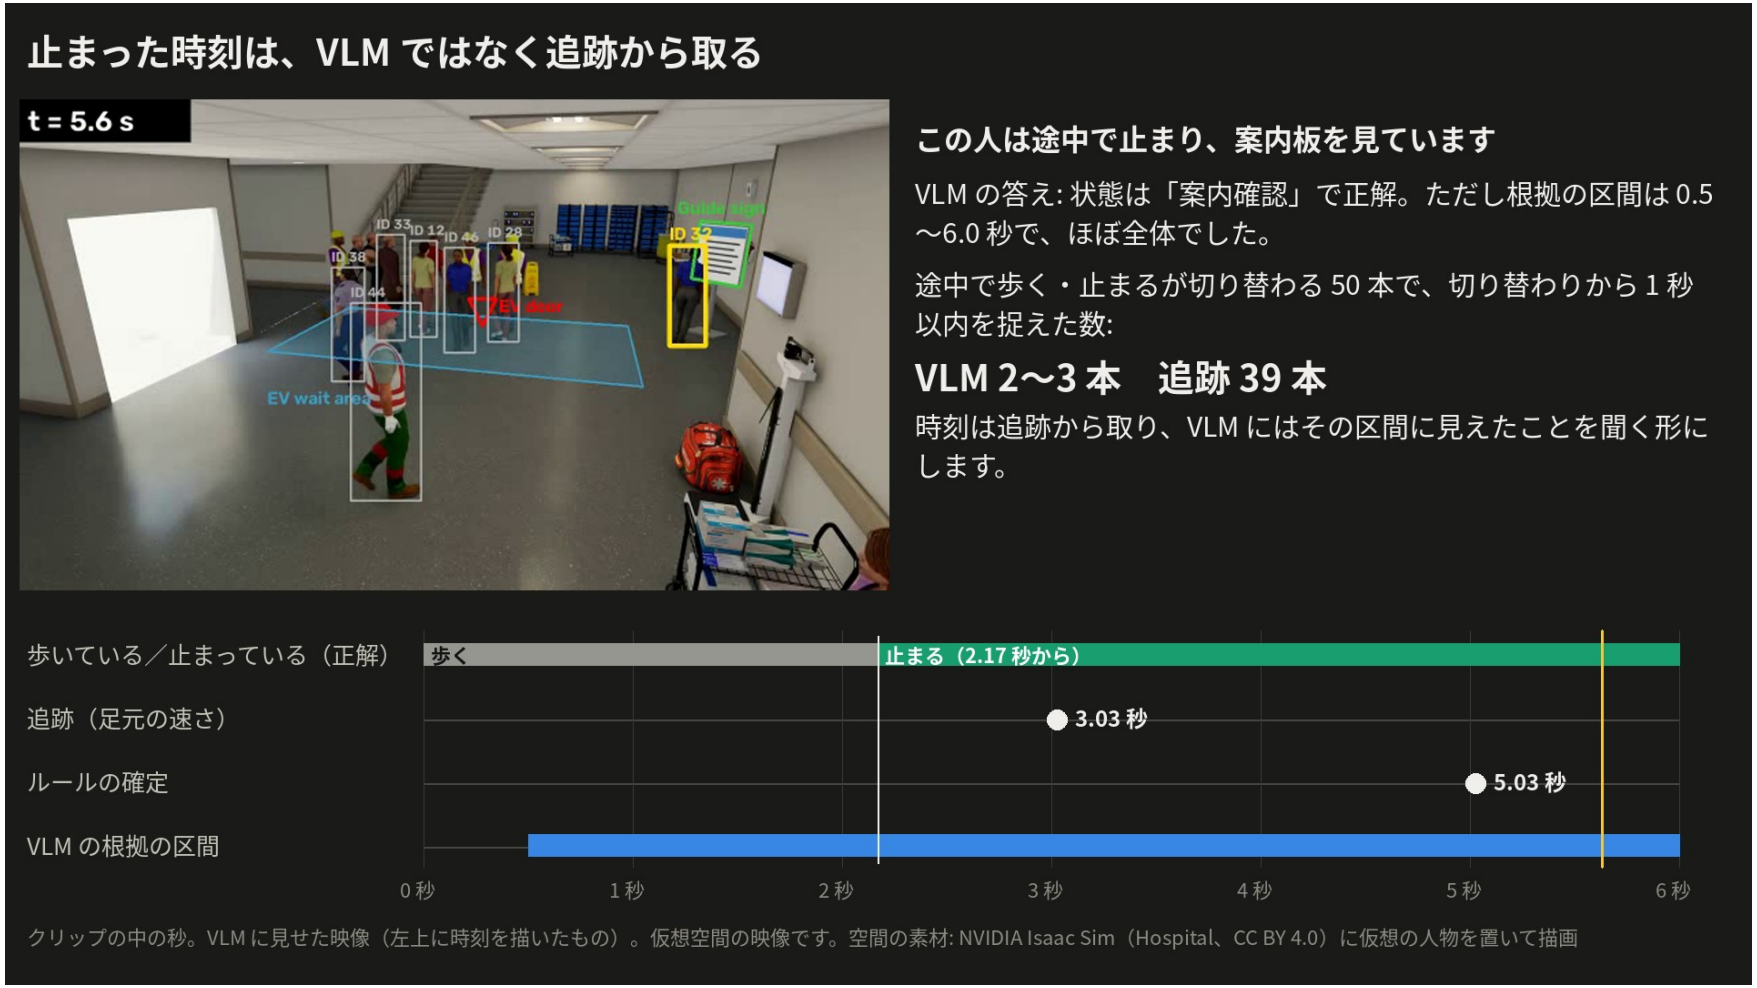
- 左: EV を待つ人の向きを「他の方向」と答え、同行者待ちと判定（広間 A）
- 右: 待ちエリアの中の同行者の向きを「扉」と答えた（広間 B）。この種類のクリップ 13 本のうち、見分けられたのは 3 本

結果: 止まった時刻は、VLM ではなく追跡から取る

時刻の取り方	切り替わりから 1 秒以内（50 本中）	誤差の中央値
VLM の根拠の区間	2〜3 本	1.03〜1.15 秒
VLM のコマごとの答え	1 本	—（境い目を出せたのが 1 本だけ）
追跡（足元の速さ）	39 本	0.83 秒
ルールの確定	0 本	2.9 秒（確定するまで待つので遅れる）

- 途中で歩く・止まるが切り替わる 50 本で比べた。VLM は 44 本で区間がクリップ全体で、状態が合っていても時刻は出ない
- コマに時刻を描き込み、動作ごとの区間やコマごとの歩いているかを聞いても、変わらなかった
- **根拠の区間は追跡の区間を使い、VLM にはその区間に見えたことを聞く形に変える**

映像: 状態は合っていても、時刻は出ない



下の時間軸の縦線が今の時刻。仮想空間の映像（竹芝の映像ではありません）。空間の素材: NVIDIA Isaac Sim（Hospital、CC BY 4.0）

結果: 全部の候補に VLM を使うと、計算量が大きい

項目	広間 A（位置で分かる）	広間 B（位置で分からない）
VLM の呼び出し（1 分あたり）	115 回	80 回
GPU の時間（映像 1 時間あたり）	9,286 秒	7,211 秒
カメラ 1 台に要る GPU	2.6 枚分	2.0 枚分
映像の 10〜20% に絞った場合（計算上）	0.26〜0.52 枚分	0.20〜0.40 枚分
VLM の答えがある時間の割合	70%	66%
同行者待ちと判定するまでの遅れ（中央値）	4.5 秒	4.75 秒

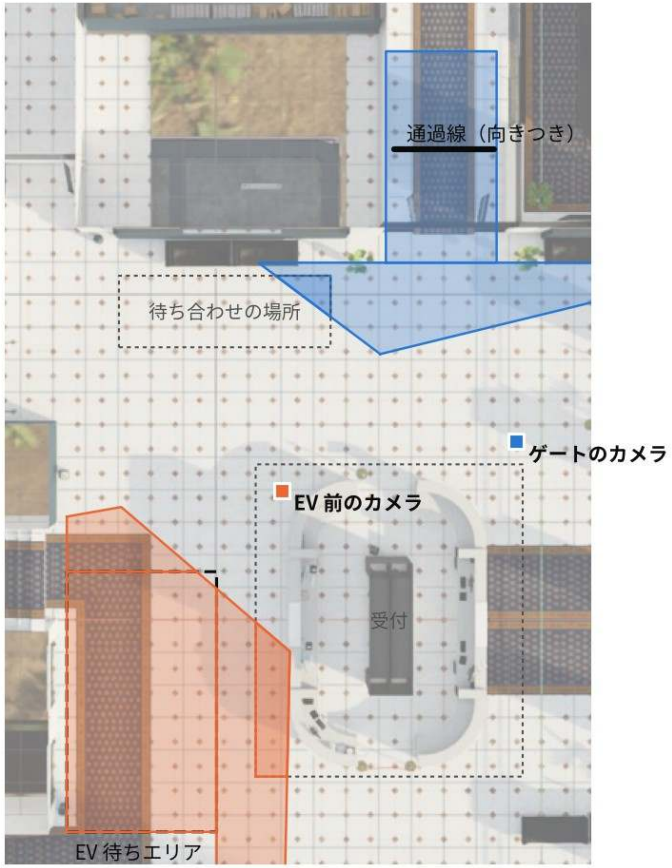
- GPU は RTX PRO 6000（8 本ずつまとめて処理）。VLM の部分だけで、検出・追跡は含まない。遅れに VLM の処理の時間は入れていない
- **実時間で動かすには映像を選ぶことが前提。位置で分からない候補に絞る案が、今回の結果から出てきた（研究課題 2、12 月に比べる）**

見えてきた課題

課題	値（仮想の広間）	何が起きているか
混雑時の人数	誤差 3.97 人（平均 10.8 人）	平均 4.5 人が手前の人に隠れ、見逃しがそのまま誤差になる。VLM では直らない
グループ	見つけた組 0 / 正解 26 組	一緒に歩く時間が短く、追跡の ID の切り替わりで途切れる
案内確認（広間 B）	F1 0.29	案内板のすぐ隣で EV を待つ人と混ざる
待ちエリアの中の同行者	13 本中 3 本	向きが扉と答えられると見分けられない
判定の遅れ	4.5〜4.75 秒	クリップの終わりに答えるため（処理の時間を除く）

人数の流れは、仮想のオフィスで手順を確認した

指標（5 分・94 人・カメラ 2 台）	正解との差・値
ゲートの人数の誤差	0.63 人（平均 2.3 人）
ゲートの方向の F1	0.93
EV 前の人数の誤差	0.60 人（平均 4.5 人）
EV 待ち人数の誤差	1.03 人
入館から 5 分以内に EV 前に現れた割合	正解 0.90・推定 0.85
現れるまでの秒（中央値）	正解 12.4・推定 12.4



仮想のオフィスの床の図

言えること・言えないこと

- **言えること**
  - 映像 → 追跡 → VLM → 評価まで動き、評価仕様の指標が全部出る
  - 仮想の 2 場面では、VLM の向きが上回るのは位置で分からない場面だけ
  - 今の VLM（Qwen3-VL-8B）では、止まった時刻は取れない
- **言えないこと**
  - 竹芝での性能（実際の映像はまだない）
  - 実際の人でも向きが手がかりになるか（仮想の同行者は相手が来る方を向く設定で、場面を作る側が決めた）
  - 位置のルールの値が実際にも出るか（電話・立ち話など別の理由で止まる人が仮想の場面にほとんどいない）
  - ばらつき（仮想の 2 場面・VLM 1 種類・1 回の生成）
  - 逆光・光の変化、荷物やスマホ、服装の多様さの影響（人物モデルは 10 種類）

これから進めること

時期	内容	前提
すぐ	根拠の区間を追跡から取る形に、評価の道具を変えて測り直す	なし
すぐ	位置で分からない候補だけに VLM を使う形を、同じ評価で測る	なし
すぐ	長い場面（15 分以上）・逆光のある場面で、時間帯別の集計を試す	なし
映像の受け取り後	サンプル映像で手順を通す（開発用だけ）。竹芝の EV 前が、位置で分かる現場か分からない現場かを確かめる	ご確認の 5 点
11 月	基準の数値を取る（条件確定のあと）	録画の保全・切り出し
12 月	方式と映像の選び方を比べる。数値の基準は事前に登録する	基準の数値

ご確認いただきたい 5 点

#	ご確認いただきたいこと	ご担当
1	録画の保存期間と保全の可否（仮の案: 11 月の平日 10 日・2 台・8:00〜19:00）。上書きされると取り返せないので、いちばん急ぐ	東急不動産
2	NDA の状況と締結の見込み。映像はサンプルも含めて締結のあとに受け取る	東急不動産・ソフトバンク
3	処理する場所（専用の GPU サーバーの納品まで、研究室の共用サーバーの担当者だけが読めるフォルダで扱ってよいか）	東急不動産
4	映像の扱い（顔のぼかしと事前の確認、ソフトバンクへは集計だけ、告知、ラベル付けの環境、終了時の消去）	東急不動産・ソフトバンク
5	条件確定の打ち合わせの日程	ソフトバンク

補足: 詳しい数値

場面	方式	F1（95% 区間）	受理率	同行者待ち	案内確認	EV 待ち	通過
広間 A（位置で分かる）	評価仕様どおりのルール	0.434（0.41〜0.45）	1.00	0.00	0.65	0.90	0.61
	位置のルール	0.594（0.57〜0.61）	1.00	0.83	0.65	0.90	0.61
	VLM に状態を聞く	0.403（0.39〜0.42）	0.99	0.00	0.50	0.90	0.62
	組み合わせ	0.421（0.40〜0.44）	0.99	0.00	0.59	0.87	0.59
	ルール＋VLM の向き	0.533（0.51〜0.55）	1.00	0.62	0.59	0.86	0.61
	ルール＋向き（映像だけ）	0.499（0.47〜0.53）	1.00	0.43	0.62	0.85	0.61
広間 B（位置で分からない）	評価仕様どおりのルール	0.298（0.29〜0.31）	1.00	0.00	0.00	0.84	0.64
	位置のルール	0.415（0.39〜0.44）	1.00	0.59	0.00	0.84	0.64
	VLM に状態を聞く	0.359（0.33〜0.38）	0.99	0.00	0.24	0.85	0.66
	組み合わせ	0.354（0.33〜0.38）	0.99	0.00	0.28	0.82	0.62
	ルール＋VLM の向き	0.487（0.42〜0.53）	0.99	0.62	0.29	0.83	0.64

- 評価仕様どおりのルールは、決まった待ち合わせ場所がないと「その他」と答える（この場面に待ち合わせ場所はない）。本編の位置のルールは、その行を同行者待ちに変えたもの

補足: 評価のしかたと、10 月の予備実験の値との違い

- **評価のしかた**
  - 人 × 0.5 秒ごとに、その時点までの映像で出した最新の判定を正解と比べる
  - VLM の答えは 8 秒で切れ、切れたらルールの判定に戻る。不明は誤りに数える
  - 5 つの状態の平均なので、どの方式もほとんど当たらない「その他」（F1 0.00〜0.05）が値を下げている
- **10 月の予備実験の値との違い**
  - 10 月の値は広間 A で位置のルール 0.80・向き 0.78、広間 B で 0.64・0.70
  - 順位は今回と同じ（広間 A は位置のルール、広間 B は向きが上）
  - 値が低く見えるのは、評価の単位（クリップ → 人 × 0.5 秒）と平均する状態の組（6 つ → 5 つ）が変わったため。直接は比べられない

補足: 素材と使った技術

- **映像の素材**
  - 映像はすべて NVIDIA Isaac Sim で作った仮想空間。竹芝の映像・図面は使っていない
  - 空間: Isaac Sim の Hospital・Office（CC BY 4.0、https://creativecommons.org/licenses/by/4.0/）。人物を置いて描画し、カメラの映像にした
  - 人物: Isaac Sim 付属の仮想の人物モデル（10 種類）。お渡しするのは描画した映像だけ
- **使った技術**
  - 検出・追跡: MOPF（YOLO11m＋QAQS＋BoostTrack）
  - VLM: Qwen3-VL-8B（ローカルの GPU で実行し、映像を外部に送っていない）